Prijedlog projekta – Analiza slika u biomedicini

1. Ime projekta

AneuLoc – automatska detekcija i anatomska lokalizacija intrakranijalnih aneurizmi na 3D CTA i MRA snimkama mozga

Tim: Jakov Malić, Antonio Šimić, Karin Brajdić, Lovro Mihaljević

2. Tema i kratki opis projekta

Tema: Multimodalna analiza intrakranijalnih aneurizmi pomoću dubokog učenja, po uzoru na izazov TopAneu 2026 (MICCAI 2026), čiji javno dostupni skup podataka koristimo.

Odabrani zadatak: Task 1 – klasifikacija aneurizmi po lokaciji na krvnoj žili. Za zadanu 3D CTA ili MRA snimku model predviđa postoji li aneurizma na svakoj od 52 unaprijed definirane lokacije (npr. Acom kompleks, vrh bazilarne arterije, spoj ICA–Pcom, lijevo/desno). To je multi-label klasifikacija. Task 2 (višeklasna segmentacija na razini voksela) ne obrađujemo jer traži preciznije maske i zahtjevniju evaluaciju.

Motivacija: Intrakranijalne aneurizme su česte, a njihova ruptura ima teške posljedice. Za procjenu rizika i planiranje liječenja klinički je bitno ne samo otkriti aneurizmu nego i znati na kojoj se žili nalazi.

Podaci (stranica skupa podataka):

- 415 3D snimki od 408 pacijenata iz 4 centra (Švicarska, Japan, javni skupovi), modaliteti CTA i MRA
- format `.nii.gz`, snimke već odrezane na područje mozga i preorijentirane (LPS+)
- oznake: višeklasne maske lokacije aneurizme, JSON s popisom lokacija po snimci, maske tipa aneurizme te automatski dobivene (silver-standard) maske krvnih žila
- podaci su slobodni za nekomercijalnu uporabu uz navođenje izvora

Pristup u jednoj rečenici: dvostupanjski model – prvo 3D mreža pronalazi aneurizme, zatim se svakoj pronađenoj aneurizmi dodjeljuje lokacija na temelju okolne anatomije krvnih žila.

3. Razrada projekta u zadatke

Projekt dijelimo u šest zadataka; Z3 je jednostavna referentna točka, a Z4 i Z5 čine glavni dvostupanjski model.

1. **Z1 – Pregled literature i postavljanje okruženja**
   - pregled radova o detekciji aneurizmi (nnU-Net, MONAI, rješenja iz izazova ADAM i INSTED)
   - zajednički Git repozitorij, okruženje (PyTorch, MONAI, SimpleITK/nibabel), pristup GPU-u
2. **Z2 – Eksplorativna analiza i pretprocesiranje podataka**
   - statistika: broj snimki po centru i modalitetu, raspodjela 52 lokacije, veličine aneurizmi, rijetke klase
   - resampling na zajednički razmak voksela, normalizacija intenziteta posebno za CTA i MRA
   - pretvorba `location_jsons` u binarne vektore duljine 52 (ciljne oznake za Task 1)
   - podjela na train/val/test po pacijentima, s posebnim „leave-one-center-out" skupom za provjeru generalizacije (testni centar izazova nije javno dostupan)
3. **Z3 – Osnovni (baseline) model**
   - 3D CNN (npr. 3D ResNet iz MONAI-ja) nad smanjenom cijelom snimkom, izravna multi-label klasifikacija
   - funkcija gubitka: BCE ili focal loss s težinama klasa zbog neuravnoteženosti
4. **Z4 – Stupanj 1: detekcija aneurizmi**
   - binarna 3D segmentacija aneurizme (nnU-Net ili 3D U-Net) na temelju binariziranih `location_masks`
   - izdvajanje kandidata kao povezanih komponenti i filtriranje lažno pozitivnih
5. **Z5 – Stupanj 2: dodjela lokacije na žili**
   - za svakog kandidata izračun značajki iz okolnih oznaka `vessel_masks` (koje žile ga okružuju, strana lijevo/desno)
   - mali klasifikator (3D CNN nad isječkom slike + maske žila, ili gradient boosting nad značajkama) koji predviđa jednu od 52 lokacije
   - spajanje predikcija u konačni vektor od 52 vjerojatnosti po snimci
6. **Z6 – Evaluacija, analiza i izvještaj**
   - metrike po lokaciji i ukupno: osjetljivost, specifičnost, F1, AUROC, macro/micro prosjek

- usporedba baseline vs. dvostupanjski model, CTA vs. MRA, po centrima
- vizualizacija točnih i pogrešnih predikcija, analiza grešaka na rijetkim lokacijama
- završni izvještaj, prezentacija i očišćeni kod

4. Ishodi projekta

Krajnji rezultat je istrenirani model koji za novu CTA ili MRA snimku vraća popis lokacija na kojima se nalaze aneurizme.

- **Pretprocesni pipeline** za oba modaliteta i pretvorbu oznaka u format za Task 1
- **Baseline model** i **dvostupanjski model** (detekcija + lokalizacija), s istreniranim težinama
- **Evaluacija** po svih 52 lokacija i ukupno, uz usporedbu modela, modaliteta i centara
- **Vizualizacije** predikcija (presjeci snimke s označenim aneurizmama i dodijeljenom lokacijom)
- **Repozitorij** s kodom i uputama za ponovno pokretanje
- **Završni izvještaj i prezentacija** s analizom rezultata, ograničenja i mogućih poboljšanja

Cilj je da dvostupanjski model bude jasno bolji od baselinea, posebno na čestim lokacijama (Acom, ICA, MCA).

5. Dodjela poslova članovima tima

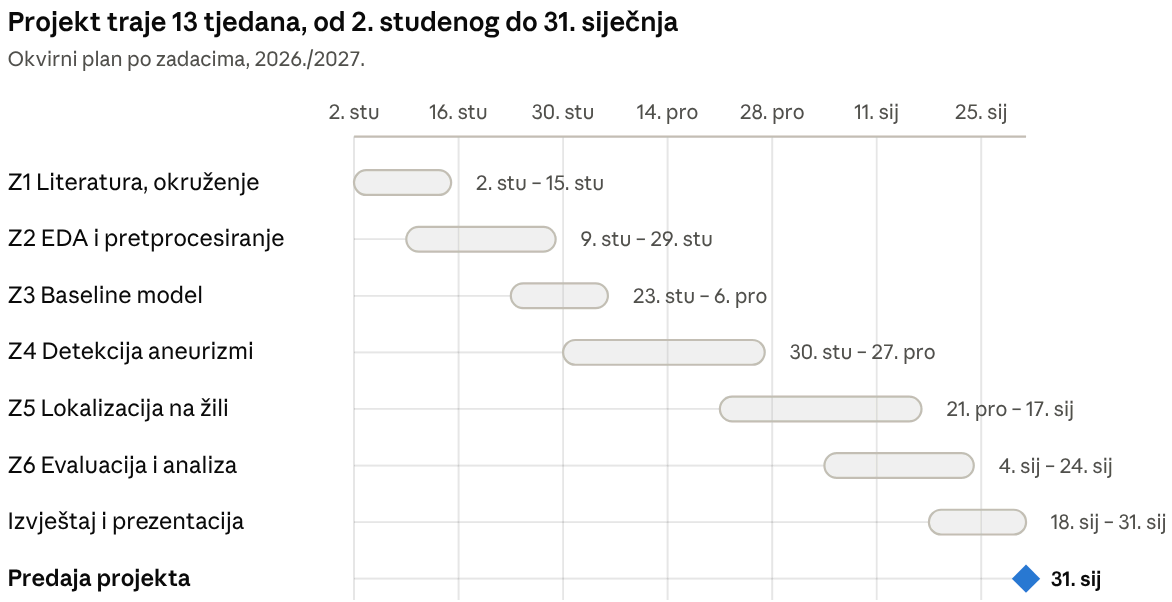
Svaki član vodi jedan dio, a pregled literature (Z1) i završni izvještaj radimo svi zajedno.

Član tima	Glavna odgovornost	Zadaci
Jakov Malić	Podaci i pretprocesiranje	Z2: učitavanje NIfTI snimki, EDA, resampling i normalizacija, pretvorba oznaka, podjela skupova
Antonio Šimić	Stupanj 1 – detekcija	Z4: treniranje 3D modela za segmentaciju aneurizmi, izdvajanje kandidata; postavljanje okruženja i GPU infrastrukture
Karin Brajdić	Baseline i stupanj 2 – lokalizacija	Z3: baseline 3D CNN; Z5: značajke iz maski žila, klasifikator lokacije

Član tima	Glavna odgovornost	Zadaci
Lovro Mihaljević	Evaluacija i vizualizacija	Z6: metrike po lokaciji, usporedbe modela/modaliteta/centara, vizualizacije, koordinacija izvještaja

6. Okvirni vremenski plan rada

Projekt traje oko 13 tjedana, od početka studenog 2026. do kraja siječnja 2027.; zadaci se djelomično preklapaju kako bi članovi radili paralelno.



vremenski plan · 6 zadataka + izvještaj, 13 tjedana